1차 임플란트 결과

Metric Learning 진단 실험 — 현재 결과 보고서

기준 시점: 2026-07-13 09:00 KST

범위: 현재까지 생성된 학습 기록, 체크포인트, 결과 파일, t-SNE 이미지 및 원격 화면 캡처만 사용

주의: 없는 체크포인트와 아직 저장되지 않은 평가 수치는 임의로 추정하지 않았다.

1. 요약

- **ViT-ClosedFT**는 closed-set 27라벨로 10 epoch 학습을 완료했다. 최종 test accuracy는 **0.9543**, test macro-F1은 **0.9267**이다.
- **ViT-ClosedFT-SupCon**은 확인된 학습 기록이 3/10 epoch까지다. 최신 test accuracy는 **0.8765**, test macro-F1은 **0.7930**이지만, 10 epoch ClosedFT와 직접 비교해 SupCon의 효과로 해석할 수 없다.
- 재사용한 **ViT-FullFT**는 42라벨 학습 기록을 가진다. 최고 validation accuracy는 **0.9514**, 최고 validation macro-F1은 **0.9106**이다. per-epoch test metric은 기록되지 않았다.
- 프로토타입 t-SNE는 **ClosedFT, ClosedFT-SupCon, FullFT** 체크포인트에 대해 생성됐다. Base와 FullFT-SupCon은 체크포인트가 없어 PASS 처리됐다.
- 각 표현 공간에서 저장된 프로토타입 좌표는 **110점**이다: GT 26점 + Mean 42점 + SS 42점.
- GT-prototype은 영문명 매핑 기준으로 closed **20/27**, open **6/15**만 매핑됐다. Mean과 SS는 closed **27/27**, open **15/15** 전체를 포함한다.
- 현재 결과만으로는 Base 대비 fine-tuning 저하 여부, SupCon의 최종 효과, Euclidean 대 cosine 우열, GT/Mean/SS의 성능 우열을 확정할 수 없다. 시각화는 확보됐지만 동일 조건의 분류 성능 표가 아직 없다.

2. 실험 구성

데이터 분할

- closed-set: 27라벨
- open-set: 15라벨
- full manifest: `/home/ubuntu/workspace/data/manifests/models_vit.csv`
- GT manifest: `/home/ubuntu/workspace/data/gt.csv` — 241행, 27개 GT 폴더
- SS 설정: 라벨당 5개 학습 샘플(`ss_per_label=5`), seed 42

open-set 15라벨은 다음과 같다.

`Simpleline`, `exfeel internal`, `55 III`, `Biohorizon external`, `TSV`, `5 clean tapered`, `GS III`, `screw vent`, `atlas internal`, `stella`, `3i`, `ankylos`, `iu`, `replace select`, `core1`

모델 및 체크포인트

Model	Checkpoint
ViT Base	없음
ViT-ClosedFT	`/home/ubuntu/workspace/outputs/20260711_202711_metricdiag_fresh_closedft27_e10/checkpoints/best.pt`
ViT-ClosedFT-SupCon	`/home/ubuntu/workspace/outputs/20260712_043644_metricdiag_fresh_closedft_supcon27_e10/checkpoints/best.pt`
ViT-FullFT	`/home/ubuntu/workspace/outputs/20260701_060811_models_vit_42class/checkpoints/best.pt`
ViT-FullFT-SupCon	없음

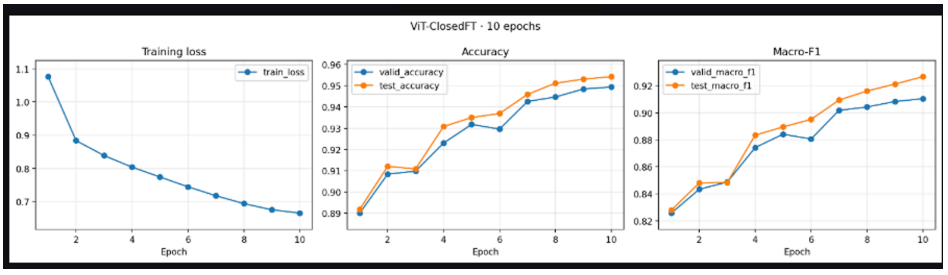
프로토타입 정의

- GT-prototype: Yonsei/AI Hub 기준 이미지를 영문 라벨명으로 매핑해 사용
- Mean-prototype: 라벨별 전체 training embedding 평균
- SS-prototype: 라벨별 training embedding 일부를 선택해 평균; 현재 설정은 라벨당 5개

3. 학습 결과

Model	Labels	기록 상태	기준 epoch	Validation accuracy	Validation macro-F1	Test accuracy	Test mac
ViT Base	42	체크포인트 없음	—	—	—	—	—
ViT-ClosedFT	27 closed	**10/10 완료**	10	**0.9494**	**0.9104**	**0.9543**	**0.9267**
ViT-ClosedFT-SupCon	27 closed	**3/10까지만 기록 확인**	3	0.8734	0.7919	0.8765	0.7930
ViT-FullFT	42 full	기존 54-epoch 기록 재사용	42 F1 / 54 acc	**0.9514**	**0.9106**	미기록	미기록
ViT-FullFT-SupCon	42 full	체크포인트 없음	—	—	—	—	—

3.1 ViT-ClosedFT — 10 epoch 완료

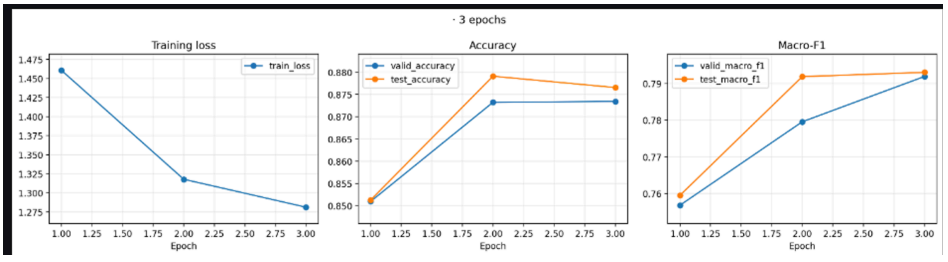


각 패널은 metric 변화가 독립적으로 보이도록 서로 다른 y축 범위를 사용한다.

Epoch	Train loss	Valid acc	Valid macro-F1	Test acc	Test macro-F1
1	1.0761	0.8980	0.8257	0.8918	0.8279
2	0.8836	0.9084	0.8433	0.9120	0.8480
3	0.8388	0.9098	0.8487	0.9109	0.8483
4	0.8039	0.9230	0.8742	0.9308	0.8834
5	0.7743	0.9318	0.8841	0.9350	0.8896
6	0.7448	0.9291	0.8805	0.9369	0.8951
7	0.7179	0.9427	0.9018	0.9459	0.9095
8	0.6942	0.9447	0.9043	0.9512	0.9161
9	0.6756	0.9485	0.9083	0.9531	0.9213
10	**0.6656**	**0.9494**	**0.9104**	**0.9543**	**0.9267**

Epoch 1→10에서 train loss는 **0.4105 감소**, validation accuracy는 **5.14%p 증가**, test macro-F1은 **9.88%p 증가**했다.

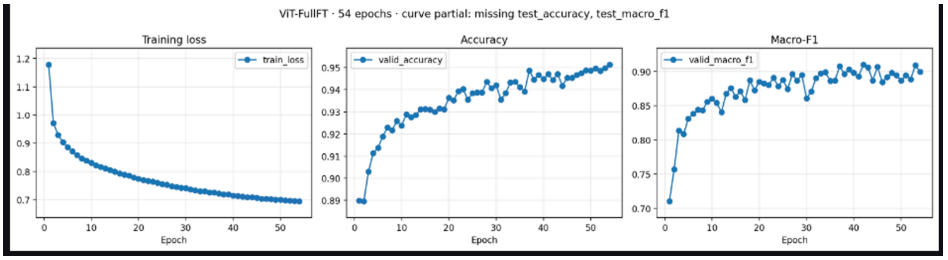
3.2 ViT-ClosedFT-SupCon — 확인된 3 epoch



Epoch	Train loss	Valid acc	Valid macro-F1	Test acc	Test macro-F1
1	1.4605	0.8510	0.7568	0.8513	0.7595
2	1.3177	0.8732	0.7795	**0.8791**	0.7918
3	**1.2811**	**0.8734**	**0.7919**	0.8765	**0.7930**

현재 수치는 3 epoch 결과다. ClosedFT의 10 epoch 결과보다 낮지만, 학습 길이가 다르므로 SupCon 자체가 성능을 저하시킨다는 결론으로 사용하지 않는다.

3.3 ViT-FullFT — 기존 54-epoch 기록

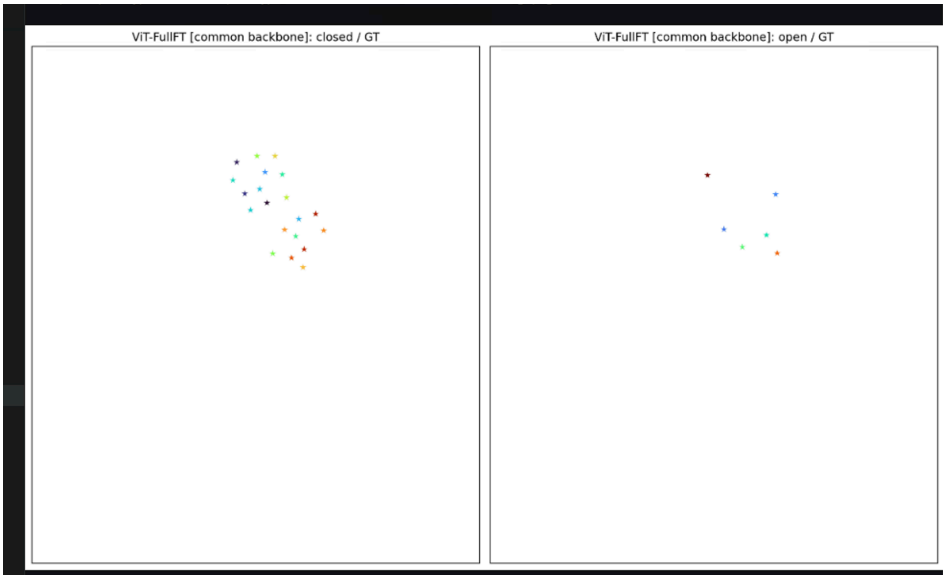


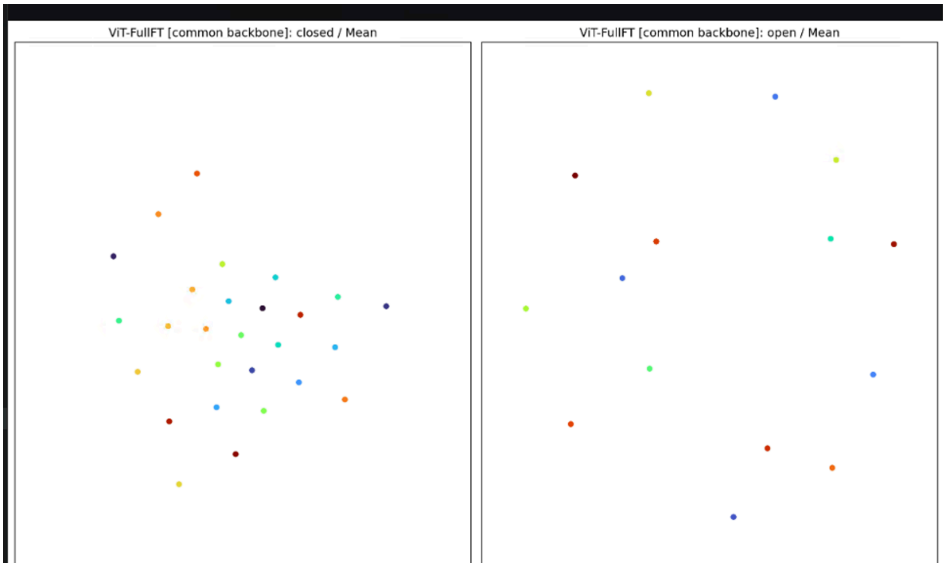
Selection	Epoch	Train loss	Valid accuracy	Valid macro-F1
Initial	1	1.1785	0.8899	0.7105
Best validation macro-F1	42	0.7116	0.9444	**0.9106**
Best/final validation accuracy	54	0.6948	**0.9514**	0.8995

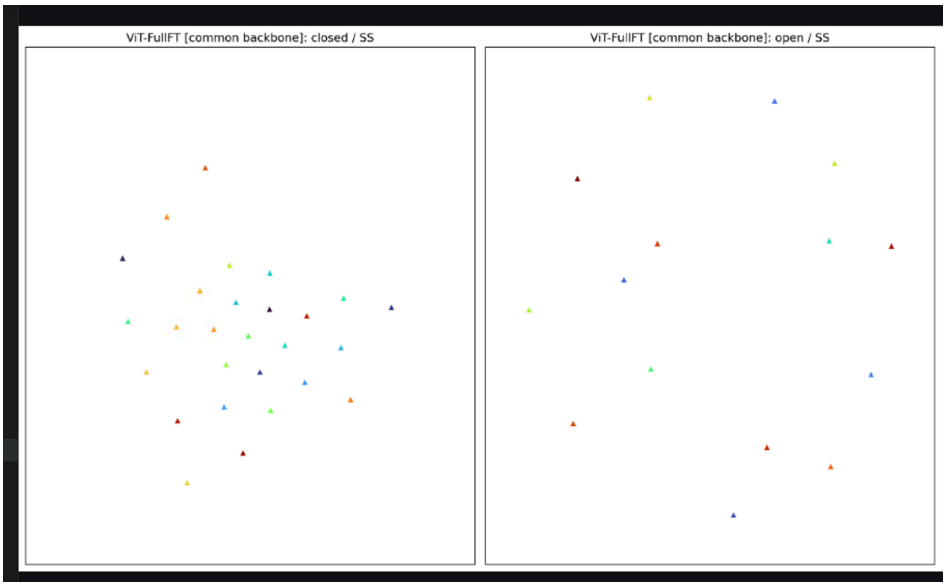
FullFT의 `history.csv`에는 per-epoch test accuracy와 test macro-F1이 없다. 따라서 이 기록만으로 open/closed test 성능을 보고하지 않는다.

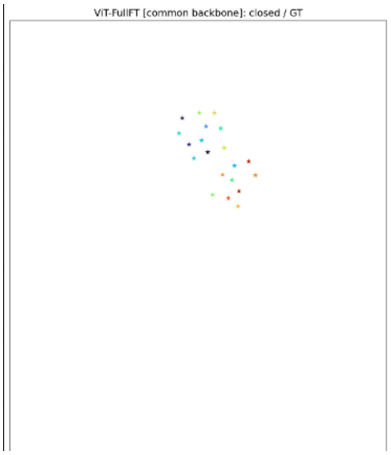
4. 현재 생성된 t-SNE 및 프로토타입 결과

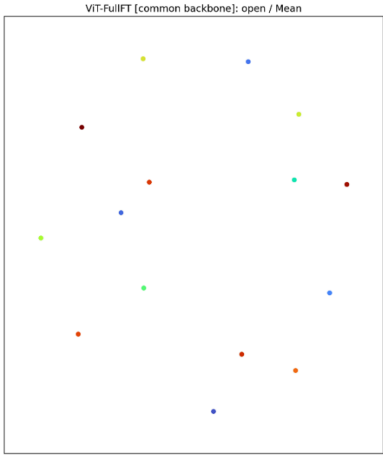
4.1 일반 classifier t-SNE — 42라벨 FullFT

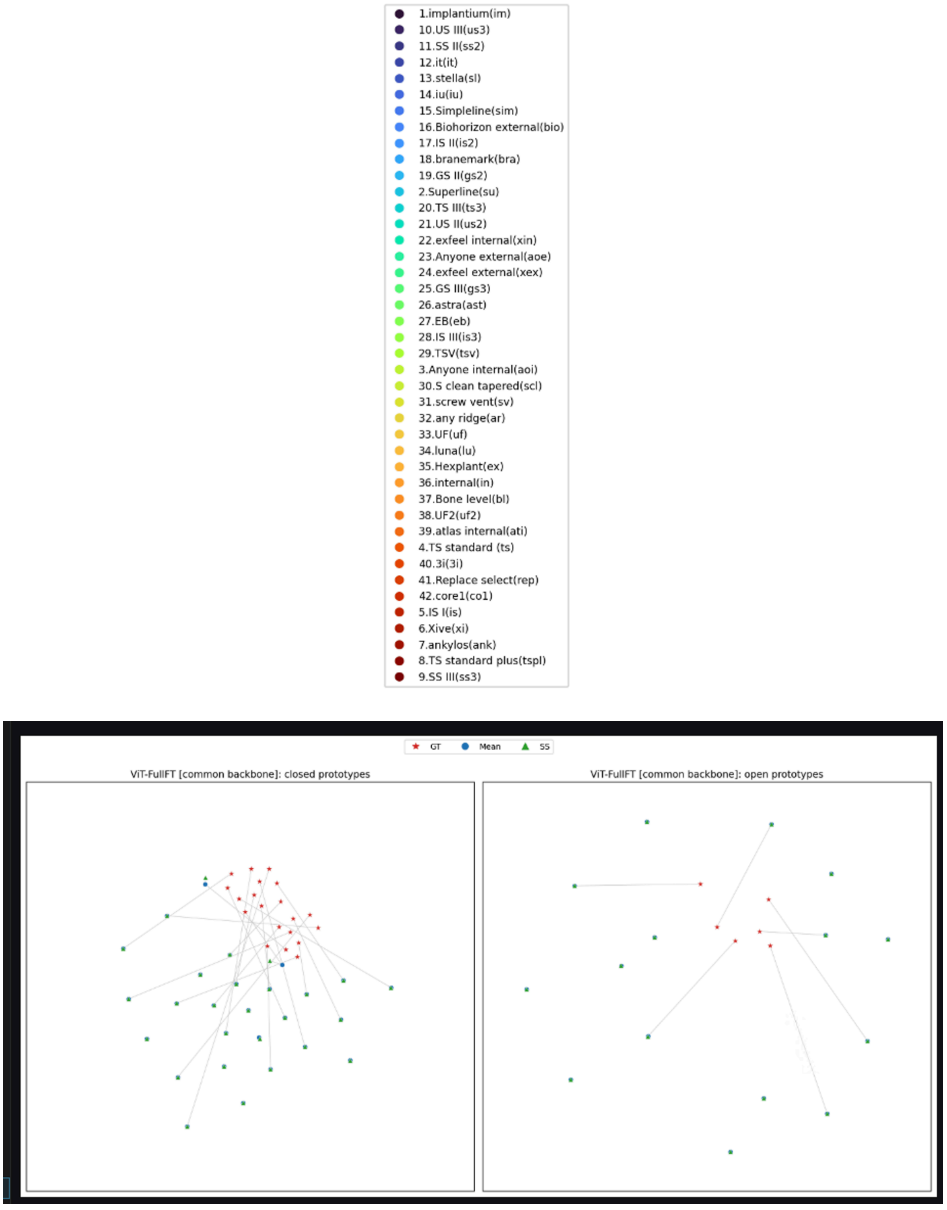



ViT-FullFT [common backbone]: closed / Mean
ViT-FullFT [common backbone]: open / Mean


ViT-FullFT [common backbone]: closed / SS
ViT-FullFT [common backbone]: open / SS

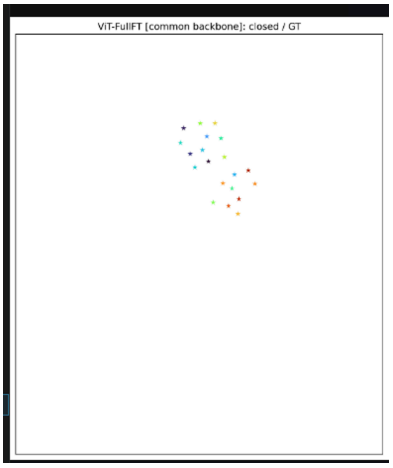

ViT-FullFT [common backbone]: closed / GT

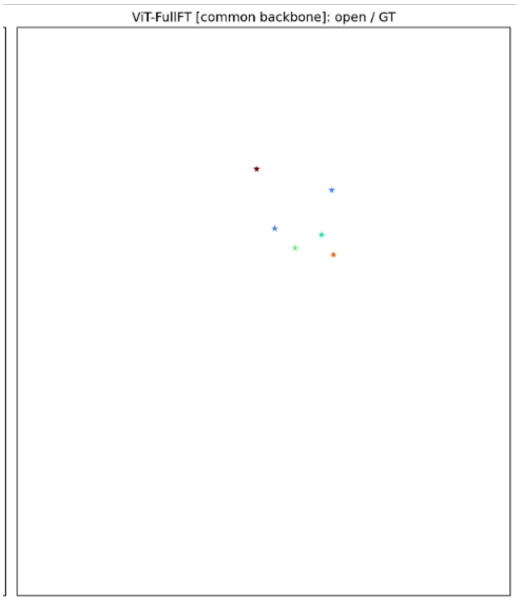

ViT-FullFT [common backbone]: open / Mean



현재 화면에서는 42라벨 점들이 크게 몇 개의 영역으로 나뉘지만, 각 영역 내부에서 여러 라벨이 섞여 있다. 캡처 안에 체크포인트와 manifest 경로가 표시되지 않으므로 특정 모델의 정량 근거로 사용하지 않고, 현재까지 생성된 전체 구조의 시각적 참고로만 사용한다.

4.2 GT 기반 metric embedding t-SNE







기존 GT/cosine-trained embedding 화면에서는 일부 라벨이 국소적으로 모여 있지만 여러 영역에서 라벨 간 혼합도 확인된다. 캡처 안에 체크포인트 경로가 표시되지 않으며 Euclidean 대응 결과도 없으므로, 이 그림 하나만으로 cosine이 우수하다고 판단할 수는 없다.

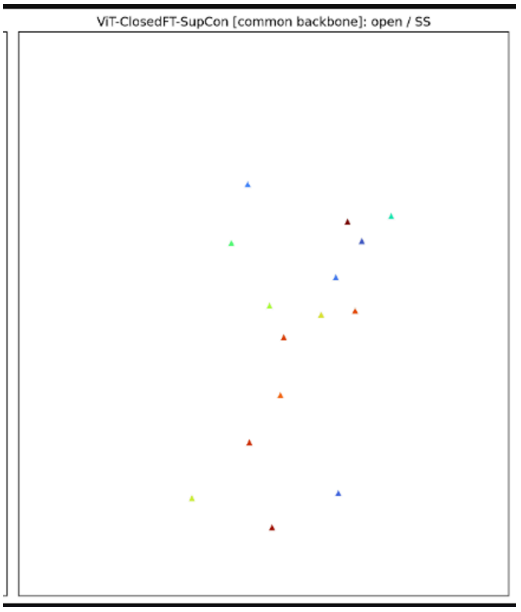
4.3 체크포인트별 프로토타입 t-SNE 생성 상태

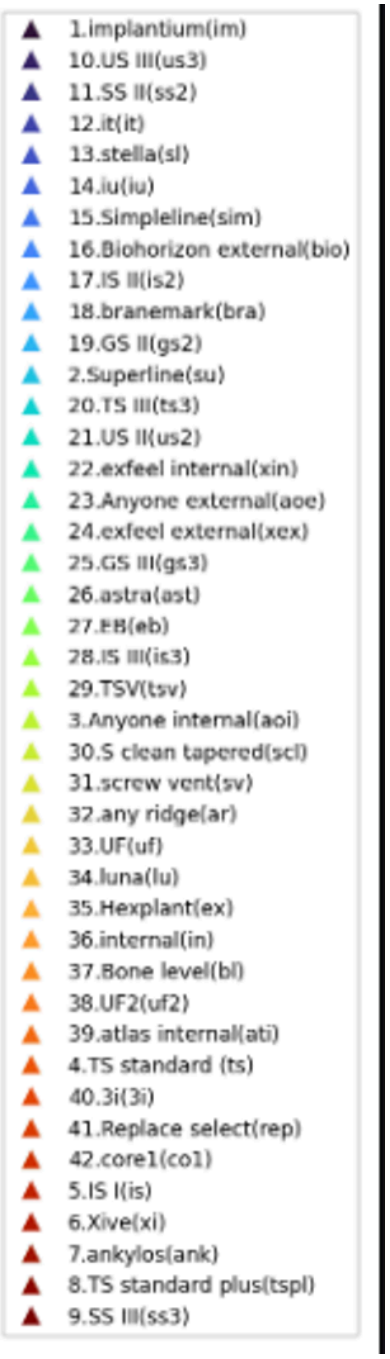
Model	Representation	상태	저장 좌표 수	GT coverage	Mean coverage	SS coverage
ViT-ClosedFT	common backbone	ok	**110**	closed 20/27, open 6/15	closed 27/27, open 15/15	closed 27/27, open 15/15
ViT-ClosedFT-SupCon	common backbone	ok	**110**	closed 20/27, open 6/15	closed 27/27, open 15/15	closed 27/27, open 15/15
ViT-ClosedFT-SupCon	deployed/projected	ok	**110**	closed 20/27, open 6/15	closed 27/27, open 15/15	closed 27/27, open 15/15
ViT-FullFT	common backbone	ok	**110**	closed 20/27, open 6/15	closed 27/27, open 15/15	closed 27/27, open 15/15
ViT Base	—	PASS	—	—	—	—
ViT-FullFT-SupCon	—	PASS	—	—	—	—

좌표 수 110은 `GT 26 + Mean 42 + SS 42`로 구성된다. GT coverage가 26/42인 이유는 현재 영문명 매핑으로 연결된 GT 라벨이 closed 20개와 open 6개이기 때문이다. Mean과 SS는 train manifest에서 직접 생성되므로 42라벨 전체를 포함한다.

ClosedFT의 SS-prototype 결과 화면은 다음과 같다.

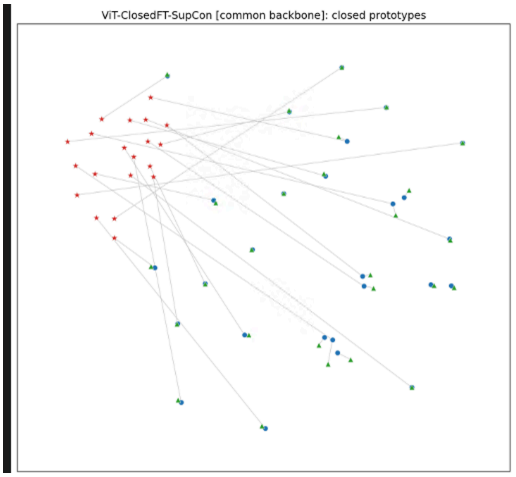


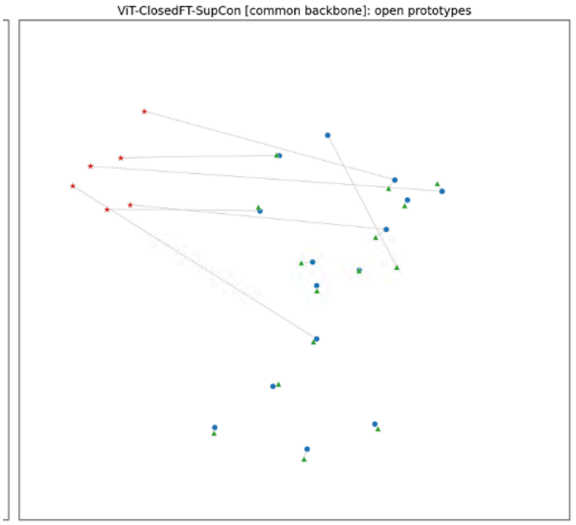


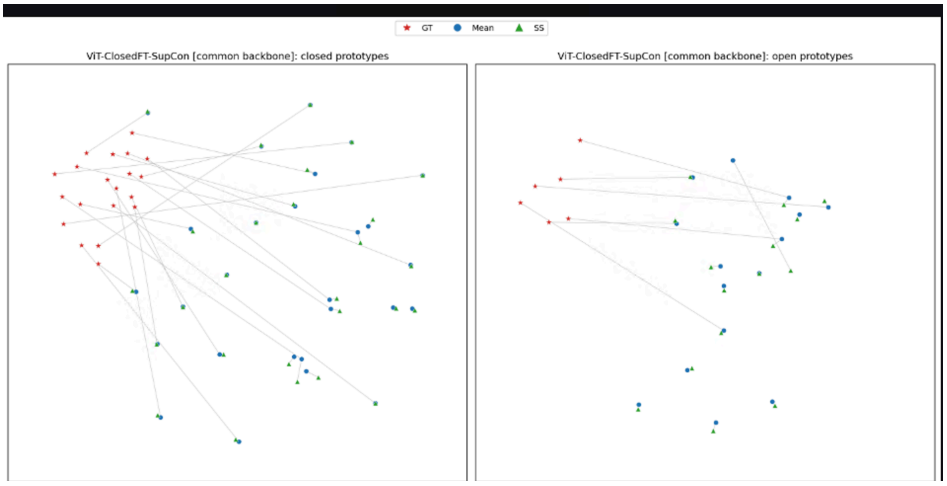


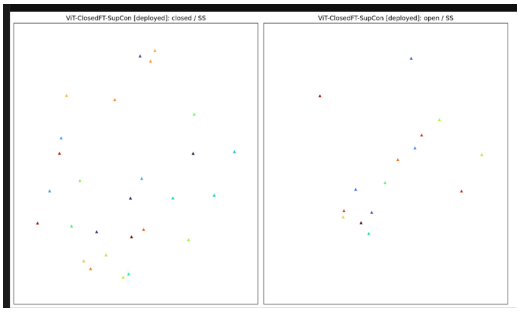
왼쪽은 closed-set, 오른쪽은 open-set 프로토타입 좌표다. SS는 라벨당 5개 샘플의 평균을 사용한다. 두 패널은 분리돼 있지만 직접 비교할 수 있도록 동일한 축 범위를 공유한다. 현재 로컬 보고서에 포함된 직접 prototype 캡처는 이 ClosedFT SS 화면이며, 나머지 완료 상태는 `progress.json`의 상태·좌표 수·coverage로 기록했다.

빨간색 = GT


ViT-ClosedFT-SupCon [common backbone]: closed prototypes

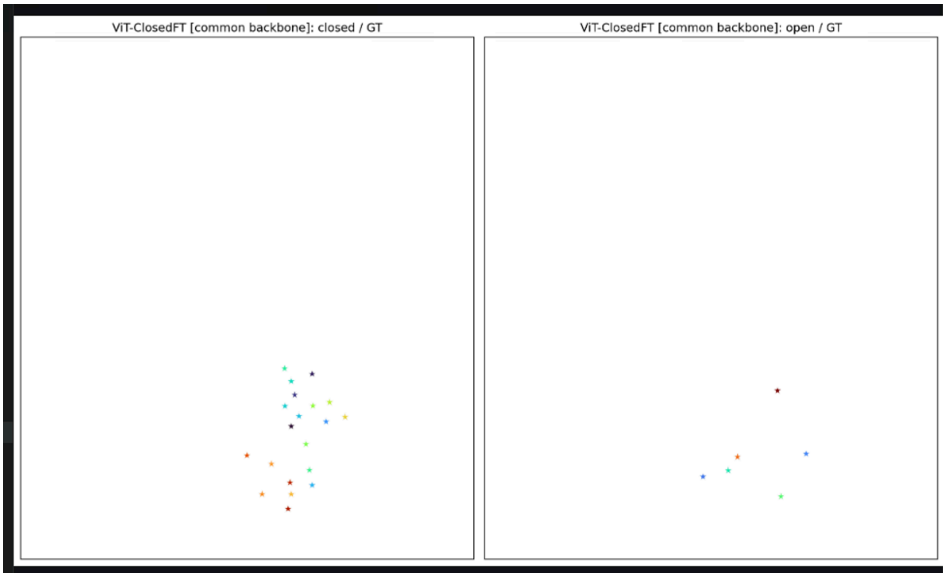

ViT-ClosedFT-SupCon [common backbone]: open prototypes

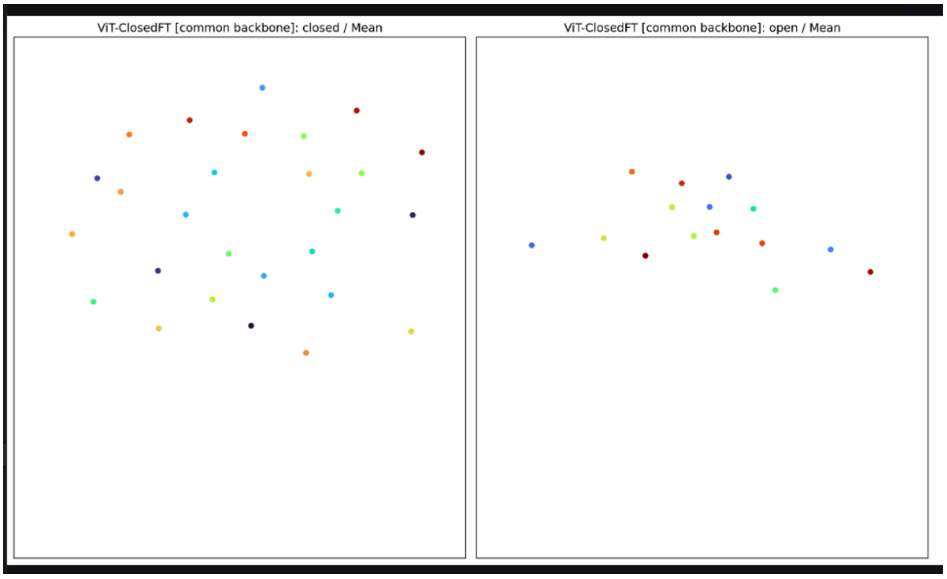

GT
Mean
SS
ViT-ClosedFT-SupCon [common backbone]: closed prototypes
ViT-ClosedFT-SupCon [common backbone]: open prototypes

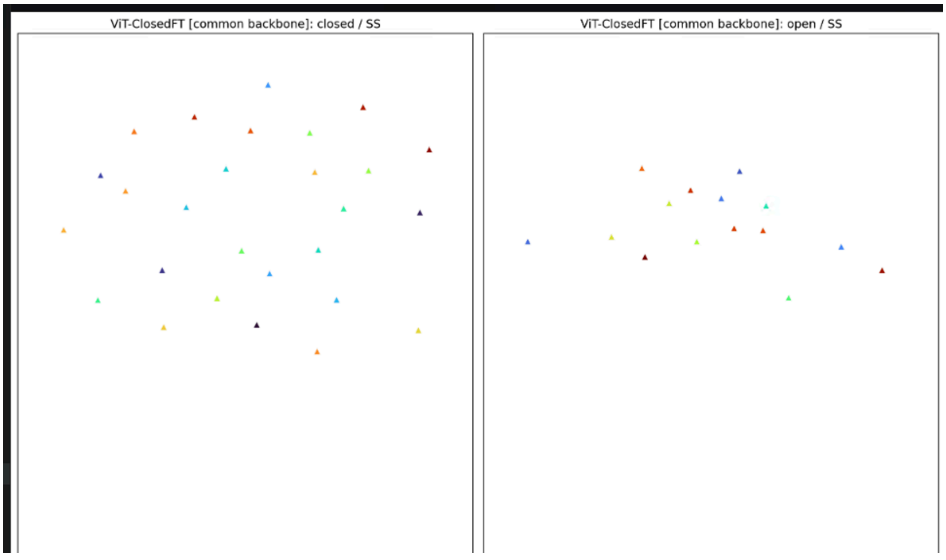

ViT-ClosedFT-SupCon [deployed]: closed / SS
ViT-ClosedFT-SupCon [deployed]: open / SS

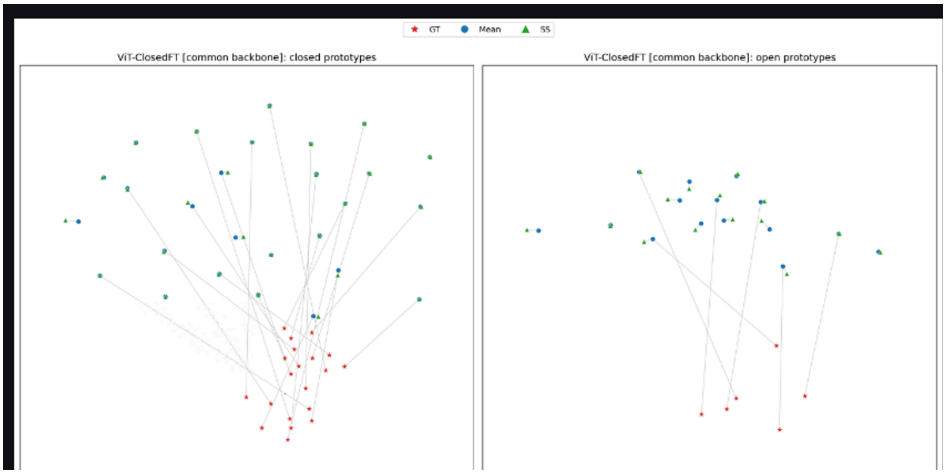

GT
Mean
SS
ViT-ClosedFT-SupCon [deployed]: closed prototypes
ViT-ClosedFT-SupCon [deployed]: open prototypes

clossed FT


ViT-ClosedFT [common backbone]: closed / GT
ViT-ClosedFT [common backbone]: open / GT


ViT-ClosedFT [common backbone]: closed / Mean
ViT-ClosedFT [common backbone]: open / Mean


ViT-ClosedFT [common backbone]: closed / SS
ViT-ClosedFT [common backbone]: open / SS



5. 연구 질문별 현재 답변

질문	현재 답변	근거와 한계
Base 대비 fine-tuning이 representation을 저하시키는가?	**미판정**	ViT Base 체크포인트가 없어 동일 manifest 조건의 Base embedding을 만들지 못했다.
SupCon이 feature representativeness에 도움이 되는가?	**미판정**	ClosedFT-SupCon의 backbone/projected t-SNE는 생성됐지만, 확인된 학습 기록은 3 epoch이고 동일 조건의 최종 accuracy/F1 비교가 없다.
full-set 학습이 도움이 되는가?	**제한적 수치만 확인**	표시된 값 기준 FullFT의 최고 validation accuracy는 ClosedFT보다 **+0.20%p**, 최고 macro-F1은 **+0.02%p** 높다. 그러나 42라벨·54 epoch와 27라벨·10 epoch 비교이므로 "FullFT가 최고"라고 확정할 수 없다.
Euclidean과 cosine 중 무엇이 좋은가?	**미판정**	cosine-trained t-SNE 화면은 있으나 동일 prototype·split에서 두 거리의 accuracy/F1 결과표가 없다.
GT, Mean, SS 중 무엇이 좋은가?	**성능 우열 미판정**	시각화와 coverage는 확보됐다. coverage 기준으로 Mean/SS는 42/42, GT는 26/42지만, 이는 라벨 가용성 차이이며 분류 성능 우열이 아니다.

FullFT와 ClosedFT의 validation 참고 비교

Metric	ClosedFT best	FullFT best	Difference (FullFT − ClosedFT)
Validation accuracy	0.9494	0.9514	**+0.20%p**
Validation macro-F1	0.9104	0.9106	**+0.02%p**

6. 실험 단계 진행표

단계	현재 상태
ClosedFT 10-epoch 학습곡선	완료
ClosedFT-SupCon 10-epoch 학습곡선	부분: 3 epoch 기록만 확인
FullFT 학습곡선	기존 54-epoch 기록 재사용
FullFT-SupCon 학습곡선	PASS: 체크포인트 없음
일반 classifier/metric t-SNE	일부 결과 화면 확보
GT/Mean/SS prototype t-SNE	ClosedFT, ClosedFT-SupCon, FullFT 완료
open/closed별 Euclidean 평가 수치	현재 결과 없음
open/closed별 cosine 평가 수치	현재 결과 없음
prototype별 최종 accuracy/F1 순위	현재 결과 없음

7. 결과 파일 위치

Artifact	Remote path
ClosedFT history	`/home/ubuntu/workspace/outputs/20260711_202711_metricdiag_fresh_closedft27_e10/metrics/history.csv`

Artifact	Remote path
ClosedFT-SupCon history	`/home/ubuntu/workspace/outputs/20260712_043644_metricdiag_fresh_closedft_supcon27_e10/metrics/history.csv`
FullFT history	`/home/ubuntu/workspace/outputs/20260701_060811_models_vit_42class/metrics/history.csv`
ClosedFT prototype t-SNE	`/home/ubuntu/workspace/outputs/prototype-tsne-closedft/prototype_tsne/`
ClosedFT prototype progress	`/home/ubuntu/workspace/outputs/prototype-tsne-closedft/progress.json`
ClosedFT-SupCon prototype t-SNE	`/home/ubuntu/workspace/outputs/prototype-tsne-closedft-supcon/prototype_tsne/`
ClosedFT-SupCon prototype progress	`/home/ubuntu/workspace/outputs/prototype-tsne-closedft-supcon/progress.json`
FullFT prototype t-SNE	`/home/ubuntu/workspace/outputs/prototype-tsne-fullft/prototype_tsne/`
FullFT prototype progress	`/home/ubuntu/workspace/outputs/prototype-tsne-fullft/progress.json`

8. 결론

현재까지 가장 확실한 수치 결과는 **ClosedFT 10 epoch의 test accuracy 0.9543 / macro-F1 0.9267**이다. FullFT는 validation에서 ClosedFT와 거의 같은 수준이며 소폭 높은 최고값을 보였지만, 데이터 범위와 epoch가 달라 최종 우열로 해석할 수 없다. 프로토타입 t-SNE는 세 체크포인트에 대해 정상 생성됐고 Mean/SS는 42라벨 전체를 포함했지만, GT는 현재 영문명 매핑으로 26라벨만 포함했다. 따라서 metric learning이 작동하지 않는 원인을 확정하려면 남은 핵심 근거는 거리별·prototype별·open/closed별 동일 조건의 수치 평가다.